




RECOMMENDATION SYSTEM

Trần Thị Kim Phụng
Tạ Văn Hoàng

April 2025



AGENDA



- 1** Project Overview
- 2** Data Exploration
- 3** Recommendation models
- 4** Model Evaluations
- 5** Next Steps


PROJECT OVERVIEW

Shopee is an "all-in-one" e-commerce ecosystem and a leading platform in Southeast Asia. Among its services, shopee.vn is one of the top e-commerce websites in Vietnam.

However, the platform currently lacks a personalized recommendation system to enhance product discovery and improve user experience.

OBJECTIVE

Develop a **recommendation system** to suggest and personalize product recommendations for users



DATA EXPLORATION



Products_ThoiTrangNam_rating_raw.csv



Products_ThoiTrangNam_raw.csv

1. Check dataset shape and structure
2. Review column names and data types
3. Check for null values
4. Check and drop duplicates
5. Identify numerical and categorical variables
6. Convert data types if needed
7. Perform descriptive statistics
8. Explore value distributions

DATA EXPLORATION - PRODUCT DATASET



Category	Thời trang nam
# Subcategory	17
# Products	49,653
Price	0 - 10M VND Avg: ~233k VND








Word	Frequency (approx.)
nam	24000
,	15500
áo	13500
-	10000
cao cấp	8000
thời trang	8000
màu	6500
thể thao	5500
thun	4500
(	4500
)	4500
cà vạt	4500
nam nữ	4500
chống	4500
phong cách	4500
đôi	4000
hàng	3500
kính	3500
]	3500
vải	3500


DATA EXPLORATION - RATING DATASET




# Products	31,267
# Users	650,636
# Duplicates	24,667



RECOMMENDATION MODELS




Collaborative Filtering



Recommendation methods	Content-based
Library	Gensim, sklearn
Model	<i>Gensim, TfidfModel</i>
Similarity Methods	<i>TF-IDF Cosin Similarity</i>
Evalutation	<i>similarity score</i>

Recommendation methods	Collaborative
Library	Pypark, Surprise
Model	ALS, SVD
Evalutation	RMSE

Content-based Filtering



COLLABORATIVE FILTERING



Input

- User_id
- Product_id
- Rating



# Users	650,636
# Products	31,267
Total count	999,815
Denominator	20,343,435,812
Sparsity	0.999



ALS

- maxIter = 20
- regParam = 0.1




RMSE = 1.14




Output

- User_id
- Product_id
- Product_name
- Sub_category
- Predicted_rating



- Rất mạnh trong xử lý dữ liệu lớn
- Phù hợp với dữ liệu thưa (sparse data)
- Có thể chạy song song

COLLABORATIVE FILTERING



	mean_test_rmse	mean_test_mae	param_n_factors	param_n_epochs	param_lr_all	param_reg_all
13	0.880996	0.555004	25	20	0.025	0.16
3	0.881015	0.553204	25	10	0.025	0.08
31	0.881285	0.555812	40	20	0.025	0.16
4	0.881338	0.558732	25	10	0.025	0.16
22	0.881444	0.559458	40	10	0.025	0.16
21	0.881452	0.554286	40	10	0.025	0.08
49	0.881654	0.556715	55	20	0.025	0.16

COLLABORATIVE FILTERING



user_id = 30

Pyspark ALS

product_name	sub_category	predicted_rating
[Không Phai Màu+Co Giãn]Quần Jean Nam Rách Gối Một Bên Màu Đen Dáng Ôm Phong Cách Hàn Quốc Hot Trend Năm 2020-J05	Quần Jeans	12.838794
Bộ ngủ Pyjama dài tay chất lụa đẹp mặc đôi dành cho nam và nữ – Đồ mặc nhà sang chảnh	Đồ Ngủ	12.138931
Tất đá bóng chống trơn lủng (Đủ màu) Tất vớ đá banh	Vớ/Tất	12.011859
combo Áo đôi	Đồ Bộ	11.906137
Quần short nam chất liệu kaki cao cấp P&B – Nhiều màu để lựa chọn – Mã TRANG500	Quần Short	11.803741
Quần đùi nam 🚚FREESHIP🚚 Quần short nam thể thao	Khác	11.801917
[FREESHIP] Vớ tất Vans CARO, Checkerboard cao cổ thể thao thời trang nam nữ	Vớ/Tất	11.798062
Cà Vạt Thời Trang Công Sở Thanh Lịch Cho Nam Kiểu Anh Quốc 6cm	Cà vạt & Nơ cổ	11.608002
Quần Dài Chống Mòn Thời Trang Leo Núi Vào Thu Đông X9	Trang Phục Truyền Thống	11.555527
Quần short jean nam nhiều màu Quần bò nam vải jean co giãn mềm mịn form cực chuẩn	Quần Short	11.510515

Surprise SVD

product_name	sub_category	predicted_rating
(CÓ SẴN) Áo khoác kimono haori happi hạc hoa	Áo Khoác	5.00
ÁO HOODIE NỈ BÔNG SIÊU DÀY IN HÌNH ĐỒNG TIỀN N...	Áo Hoodie, Áo Len & Áo Nỉ	5.00
Quần Đùi Nam Thể Thao Dáng Ngố - Quần Short Na...	Quần Short	5.00
Vớ thể thao màu đen/ trắng trơn thiết kế đơn giản	Vớ/Tất	5.00
Đôi tất cổ ngắn màu trơn 3 màu tùy chọn thời t...	Vớ/Tất	4.91
Tất thoáng khí thấm mồ hôi màu đen phong cách ...	Vớ/Tất	4.85
[A3] Áo khoác dù áo gió cặp nam nữ Loca 2 lớp	Đồ Bộ	4.83
Cà Vạt Họa Tiết Sọc Chéo Nhiều Kiểu Thời Trang...	Cà vạt & Nơ cổ	4.83
Quần Jogger Kaki Nam Nữ Túi Hộp Unisex Streetstye	Quần Dài/Quần Âu	4.75
Tất , vớ Naiiki thể thao cổ cao	Vớ/Tất	4.71

CONTENT-BASED FILTERING

Clean Data

Loại Data Invalid	Ví dụ	Cách Xử Lý	Kết Quả
URL không hợp lệ	- http://invalid-domain - https:// - ftp://website.com - just_plain_text	Sử dụng <code>is_valid_url()</code> để kiểm tra và loại bỏ	Loại bỏ các rows có URL không hợp lệ
Chữ số trong văn bản	"Áo size 42 cotton 100%"	Sử dụng <code>re.sub('[0-9]+', '', text)</code>	"Áo size cotton %"
Từ không phải tiếng Việt	- "best product" - "good quality" - "size M"	Sử dụng <code>is_valid_vietnamese()</code> để lọc	Chỉ giữ lại các từ tiếng Việt hợp lệ
Ký tự đặc biệt	- "Áo #1" - "Quần @home" - "Giày *mới"	Sử dụng pattern trong <code>is_valid_vietnamese()</code>	Chỉ giữ lại các ký tự tiếng Việt và chữ số
Giá trị null/NaN	- None - NaN - null	Kiểm tra <code>isinstance(text, str)</code>	Trả về chuỗi rỗng ""
Khoảng trắng thừa	" áo thun cotton "	Sử dụng <code>split()</code> và <code>join()</code>	"áo thun cotton"

CONTENT-BASED FILTERING

Before building models, we combined Content

Trước	Sau (Content)
Các cột riêng biệt: - product_name: "Áo ba lỗ thun gân" - category: "Thời Trang Nam" - sub_category: "Áo Ba Lỗ" - description_clean: "chất liệu cotton thoáng mát..."	Cột Content (đã gộp): "Áo ba lỗ thun gân Thời Trang Nam Áo Ba Lỗ chất liệu cotton thoáng mát..."

Unthesa word_tokenize

Remove stop word

Trước (Content)	Sau (Content_wt)
"Áo ba lỗ thun gân ,form body tôn dáng Thời Trang ..."	"Áo lỗ thun gân , form body tôn_dáng Thời_Trang ..."
"Áo Ba Lỗ Nam Trắng Chất Cotton Siêu Mát, Siêu ..."	"Áo Ba_Lỗ Nam_Trắng Chất_Cotton Siêu_Mát , Siêu..."
"ÁO BA LỖ HÀNG VIỆT NAM 100% COTTON Thời Trang ..."	"ÁO BA_LỖ HÀNG_VIỆT_NAM 100 % COTTON Thời_Trang..."

items.csv

CONTENT-BASED FILTERING

Model: Gensim

items.csv

Preprocess text

remove number
remove special characters
convert to lowercase

Trước (Content_wt)	Sau (content_re)
"Áo lỗ thun gân, form body tôn_dáng Thời_Trang Nam_Áo Ba_Lỗ"	['áo', 'lỗ', 'thun', 'gân', 'form', 'body', 'tôn_dáng', 'thời_trang', 'nam_áo', 'ba_lỗ']
"Áo Ba_Lỗ Nam_Trắng Chất_Cotton Siêu_Mát, Siêu_Đẹp"	['áo', 'ba_lỗ', 'nam_trắng', 'chất_cotton', 'siêu_mát', 'siêu_đẹp']
"Áo Ba_Lỗ Nam_Tyasuo chất vải co_dãn mát"	['áo', 'ba_lỗ', 'nam_tyasuo', 'chất', 'vải', 'co_dãn', 'mát']

Trước (content_re)	Sau (dictionary, corpus)
['áo', 'lỗ', 'thun', 'gân', 'form', 'body']	Dictionary: {'áo': 0, 'lỗ': 1, 'thun': 2, 'gân': 3, 'form': 4, 'body': 5}
	Corpus: [(0, 1), (1, 1), (2, 1), (3, 1), (4, 1), (5, 1)]
['áo', 'ba_lỗ', 'nam_trắng', 'cotton']	Dictionary: {'áo': 0, 'ba_lỗ': 6, 'nam_trắng': 7, 'cotton': 8}
	Corpus: [(0, 1), (6, 1), (7, 1), (8, 1)]


CONTENT-BASED FILTERING



Model: Gensim



Trước (corpus)	Sau (similarity_matrix)
<code>[(0, 1), (1, 1), (2, 1), (3, 1), (4, 1), (5, 1)]</code>	<code>[0.2, 0.5, 0.3, 0.1, ...]</code>
<code>[(0, 1), (6, 1), (7, 1), (8, 1)]</code>	<code>[0.1, 0.4, 0.6, 0.2, ...]</code>



based on product_id

Recommendations based on Product ID 19656:

Original product:

product_id	19656
product_name	(A393) DỆT KIM ĐÔNG XUÂN ÁO MAY Ô NAM 3 LỖ MÀU...
category	Thời Trang Nam
sub_category	Áo Ba Lỗ
image	NaN
price	72000.0
rating	5.0
Content_wt	(A393) DỆT_KIM_ĐÔNG_XUÂN_ÁO_MAY_Ô_NAM_3_LỖ_M...
Name	1156, dtype: object

Recommended products:

	product_id	product_name	category	sub_category	Content_wt	similarity_score
126	19126	Áo Ba Lỗ Nam 100% Cotton Mặc nhà Thoáng Mát	Thời Trang Nam	Áo Ba Lỗ	Áo Ba_Lỗ Nam 100 % Cotton Mặc Thoáng_Mát Thời_...	0.264407
56	1956	[Xả Kho]Áo Ba Lỗ Nam 100% Cotton Mặc nhà Thoán...	Thời Trang Nam	Áo Ba Lỗ	[Xả Kho]_Áo Ba_Lỗ Nam 100 % Cotton Mặc Thoán...	0.258865
661	191461	ÁO BA LỖ HÀNG VIỆT NAM 100% COTTON	Thời Trang Nam	Áo Ba Lỗ	ÁO BA_LỖ HÀNG_VIỆT_NAM 100 % COTTON Thời_Trang...	0.256237
3	193	ÁO BA LỖ HÀNG VIỆT NAM 100% COTTON	Thời Trang Nam	Áo Ba Lỗ	ÁO BA_LỖ HÀNG_VIỆT_NAM 100 % COTTON Thời_Trang...	0.254660
804	19304	Áo ba lỗ, áo ba lỗ nam cao cấp - Hàng Việt nam...	Thời Trang Nam	Áo Ba Lỗ	Áo lỗ , áo lỗ nam cao_cấp - Hàng Việt_nam chất...	0.246844

based on keywords

Recommendations for keyword: áo thun nam cotton

	product_id	product_name	category	sub_category	Content_wt	similarity_score
18452	241323	Sét bộ thun gồm 2 áo 1 quần 115k	Thời Trang Nam	Đồ Hóa Trang	Sét thun 2 áo 1 quần 115 k Thời_Trang Nam_Đồ H...	0.380703
188	19188	[SALE] 99k Áo thun nam 3 lỗ- áo thun nam tank ...	Thời Trang Nam	Áo Ba Lỗ	[SALE_] 99 k Áo thun nam 3 lỗ - áo thun nam t...	0.356474
6059	1875	Áo Thun polo Nam KINSMAN Tay Ngắn Thêu Gấu có ...	Thời Trang Nam	Áo	Áo Thun polo_Nam KINSMAN_Tay Ngắn Thêu_Gấu cổ ...	0.343634
17256	234922	Bộ Quần áo thể thao cotton thun lạnh phối kẻ nam	Thời Trang Nam	Đồ Bộ	Bộ Quần_áo thể_thao cotton thun lạnh_phối kẻ n...	0.342139
17325	234991	Đồ đôi nam nữ váy thun kết hợp cùng áo thun na...	Thời Trang Nam	Đồ Bộ	Đồ đôi nam_nữ váy thun kết_hợp áo thun nam thê...	0.341745

CONTENT-BASED FILTERING

Model: TfidfVectorizer, cosine_similarity

Trước (tfidf_matrix)	Sau (cosine_sim)
TF-IDF vector cho "Áo lỗ thun gân": [0.5, 0.3, 0.2, 0.0, ...]	Độ tương đồng với các sản phẩm: [1.0, 0.4, 0.3, 0.2, 0.1]
TF-IDF vector cho "Áo Ba Lỗ Nam Trắng": [0.2, 0.5, 0.0, 0.3, ...]	Độ tương đồng với các sản phẩm: [0.4, 1.0, 0.6, 0.3, 0.2]
TF-IDF vector cho "Áo Ba Lỗ Nam Tyasuo": [0.1, 0.4, 0.5, 0.0, ...]	Độ tương đồng với các sản phẩm: [0.3, 0.6, 1.0, 0.4, 0.3]



based on product_id

Recommendations based on Product ID 19656:						
	product_name	category	sub_category	content	similarity_score	
2192	Áo may ô Dệt Kim Đông Xuân 154 A0396	Thời Trang Nam	Áo Hoodie, Áo Len & Áo Nỉ	Áo may ô Dệt Kim Đông Xuân 154 A0396 Thời Trang...	0.349554	
194	Áo Ba Lỗ Nam CAO CẤP 100% Cotton	Thời Trang Nam	Áo Ba Lỗ	Áo Ba Lỗ Nam CAO CẤP 100 % Cotton Thời Trang N...	0.335858	
126	Áo Ba Lỗ Nam 100% Cotton Mặc nhà Thoáng Mát	Thời Trang Nam	Áo Ba Lỗ	Áo Ba Lỗ Nam 100 % Cotton Mặc Thoáng Mát Thời...	0.334191	
661	ÁO BA LỖ HÀNG VIỆT NAM 100% COTTON	Thời Trang Nam	Áo Ba Lỗ	ÁO BA LỖ HÀNG VIỆT NAM 100 % COTTON Thời Trang...	0.330581	
56	[Xả Kho]Áo Ba Lỗ Nam 100% Cotton Mặc nhà Thoán...	Thời Trang Nam	Áo Ba Lỗ	[Xả Kho]Áo Ba Lỗ Nam 100 % Cotton Mặc Thoán...	0.330022	

based on keywords

Recommendations for keyword: áo thun nam cotton						
	product_name	category	sub_category	content	similarity_score	
6499	Áo thun nam Jordan J2 cá tính ,áo nam vải cott...	Thời Trang Nam	Áo	Áo thun nam Jordan_J2 cá tính , áo nam vải cot...	0.292561	
21357	Áo thun nam ngắn tay cotton tinh khiết cổ V 20...	Thời Trang Nam	Đồ Hóa Trang	Áo thun nam ngắn tay cotton tinh_khiết cổ V 2021 p...	0.255124	
1095	Áo thun nam ba lỗ in số 79- FORMEN SHOP- FMTD038	Thời Trang Nam	Áo Ba Lỗ	Áo thun nam lỗ in 79 - FORMEN_SHOP - FMTD038 T...	0.250886	
6911	Áo phông trơn thun nam cotton 100% cổ tròn tay...	Thời Trang Nam	Áo	Áo phông trơn thun nam cotton 100 % cổ tròn ng...	0.245308	
6504	Áo thun nam ngắn tay in hình D A S không cổ Na...	Thời Trang Nam	Áo	Áo thun nam ngắn tay in hình_D A_S không cổ_Nam_Nữ...	0.232716	

MODEL EVALUATIONS

Method	Model name	Results	Comments	Pros	Cons
Collaborative filtering	SVD	RMSE = 0.88 time = 4 (min)	Performed well after hyperparameter tuning.	Easy to use and tune; works well with sparse data.	Requires converting data to Surprise format; slower on large datasets.
	ALS	RMSE = 1.14 time = 4.1 (min)	Faster and scalable for large datasets.	Scalable for big data; integrates well with Spark pipelines.	Lower accuracy (RMSE); less customizable than Surprise.
Content-based filtering	Gensim	similarity score: 0.2-0.4	Effective for semantic similarity analysis	Captures semantic meaning well; works on raw text.	Requires well-cleaned input and lots of training data.
	Cosin similarity	similarity score: 0.2-0.4	Simple and efficient implementation	Simple and interpretable; fast computation.	Doesn't understand meaning; purely vector-based

NEXT STEPS - SUGGESTION

Deploy models

Ensure models are optimized for performance and scalability, ready for widespread deployment across your platform.

A/B testing


Run experiments by showing different recommendation algorithms to segmented user groups, then analyze the data collected to identify which approach performs best

Gather User Feedback

Conduct surveys or interviews to understand user satisfaction and identify areas for improvement.

Continuous Model Refinement

Regularly update and retrain models with new user interaction data to enhance relevance and accuracy.



TASK ALLOCATION - LESSONS LEARNT

Tiền xử lý dữ liệu là bước quan trọng không thể thiếu

- Việc phân tích kỹ hành vi người dùng và chất lượng dữ liệu đầu vào quyết định hiệu quả của mô hình.

Không có mô hình nào là “tốt nhất” cho mọi trường hợp

- Cần thử nghiệm và so sánh nhiều mô hình (content-based, collaborative filtering, hybrid...) để chọn phương án phù hợp nhất.
- Lựa chọn model mang lại kết quả tốt nhất

Vận dụng thành thạo các thư viện áp dụng xây dựng hệ thống gợi ý

- pyspark (ALS), surprise, gensim, TfidfModel,..

Trải nghiệm người dùng là yếu tố cuối cùng quyết định thành công

- Giao diện hiển thị gợi ý, độ phù hợp và mức độ cá nhân hóa ảnh hưởng mạnh đến việc người dùng có sử dụng gợi ý hay không.
- Mô hình cần phản ánh đúng nhu cầu của doanh nghiệp: tăng tỷ lệ chuyển đổi, giữ chân người dùng, hoặc đề xuất sản phẩm mới.

Task	Member name
EDA + collaborative filtering (ALS, SVD)	Phụng
EDA + content-based (gensim + cosine similarity)	Hoàng
Slides + reports	Phụng + Hoàng



**THANK YOU FOR
LISTENING!**